



中國農業大學
China Agricultural University

《机器学习》课程——

支持向量机

主讲人： 徐义田教授

学 校： 中国农业大学



- 研究背景
- 支持向量分类机
- 支持向量回归机
- 非平衡类支持向量机
- 总结



➤ 研究背景

一、研究背景



支持向量机是解决监督学习问题中一种强大的算法

发展历史

- 1963年：Vapnik 提出支持向量机的概念
- 1968年：Vapnik 和 Chervonenkis 提出VC维
- 1974年：提出结构风险最小化原则
- 苏联解体前一年（1990），Vapnik 来到美国
- 1995年：Support vector network 文章发表
“Support-vector networks”. *Machine Learning*, 1995, 20(3):273-297. (被引数: [3.0万](#))
- 1995年：《The Nature of Statistical Learning》出版
- 1998年：SVM在文本分类中取得巨大成功
- 1998年：《Statistical Learning Theory》出版

.....

一、研究背景



应用:


① 分类问题: 特征空间: X \longrightarrow 标签: Y



文本



{运动、新闻、政治、...}




{有反应、无反应}

刺激反应

一、研究背景


② 回归问题： 特征空间： X \longrightarrow 标签： Y



价格预测



价格：\$20.50



气温预测



气温：42° F



➤ 支持向量分类机

二、支持向量分类机 (SVC)




1. 线性情况

- 完全可分 (硬间隔SVC)

给定训练集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_l, y_l)\}$, 其中 $x_i \in R^n$, $y_i \in \{-1, +1\}$

完全可分: 可以找到一条线将两类点完全分开



如何找到最优的决策超平面 $f(x) = \text{sgn}(w^T x + b)$?


二、支持向量分类机 (SVC)



1. 线性情况

- 完全可分 (硬间隔SVC)

基本思想： 基于最大化间隔的思想，分离两类点



模型： $\min_{w,b} \frac{1}{2} \|w\|^2$
s.t. $y_i((w \cdot x_i) + b) \geq 1, i = 1, \dots, l$


二、支持向量分类机 (SVC)



1. 线性情况

- 不完全可分 (软间隔SVC)

不完全可分：找不到一条线将两类点完全分开



(注：完全可分是不完全可分的特殊情况)

基本思想：基于最大化间隔的思想，**尽可能**的分离两类点

二、支持向量分类机 (SVC)



1. 线性情况

- 不完全可分 (软间隔SVC)

原问题:

$$\begin{aligned} \min_{w, b, \xi} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l \xi_i \\ \text{s.t.} \quad & y_i(w^T x_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, l \\ & \xi_i \geq 0, \quad i = 1, \dots, l \end{aligned}$$

对偶问题:

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j (x_i, x_j) \alpha_i \alpha_j - \sum_{j=1}^l \alpha_j \\ \text{s.t.} \quad & \sum_{i=1}^l y_i \alpha_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, \dots, l. \end{aligned}$$

二、支持向量分类机 (SVC)



1. 线性情况

对偶问题推导：引入拉格朗日函数：

$$L = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l \xi_i - \sum_{i=1}^l \alpha_i (y_i (w \cdot x_i + b) - 1 + \xi_i) - \sum_{i=1}^l \beta_i \xi_i$$

将 $L(w, b, \alpha)$ 分别关于 w, b, ξ_i 求导，最优性条件可得：

$$\left\{ \begin{array}{l} \textcircled{1} \quad \frac{\partial L}{\partial w} = w - \sum_{i=1}^l \alpha_i y_i x_i = 0 \quad \longrightarrow \quad w = \sum_{i=1}^l \alpha_i y_i x_i \\ \textcircled{2} \quad \frac{\partial L}{\partial b} = \sum_{i=1}^l \alpha_i y_i = 0 \\ \textcircled{3} \quad \frac{\partial L}{\partial \xi_i} = C - \alpha_i - \beta_i = 0 \quad \longrightarrow \quad 0 \leq \alpha_i \leq C \\ \textcircled{4} \quad \alpha_i (y_i (w \cdot x_i + b) - 1 + \xi_i) = 0 \\ \textcircled{5} \quad \beta_i \xi_i = 0 \\ \textcircled{6} \quad \alpha_i \geq 0, \beta_i \geq 0 \\ \textcircled{7} \quad y_i (w \cdot x_i + b) \geq 1 - \xi_i \end{array} \right. \quad \left. \begin{array}{l} \textcircled{4} \\ \textcircled{5} \end{array} \right\} \text{ 松弛互补条件}$$

二、支持向量分类机 (SVC)



1. 线性情况

- 不完全可分 (软间隔SVC)

Step 1: 解得 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_l^*)^T$

Step 2: 计算 b^* : 选取位于开区间 $(0, C)$ 中的 α^* 的分量 α_j^* , 据此计算

$$b^* = y_i - \sum_{i=1}^l y_i \alpha_i^*(x_i, x_j)$$

Step 3: 构造分划超平面 $(w^* \cdot x) + b^* = 0$, 由此求得决策函数

$$f(x) = \text{sgn}(g(x))$$

其中

$$g(x) = \sum_{i=1}^l \alpha_i y_i(x_i, x) + b$$


二、支持向量分类机 (SVC)



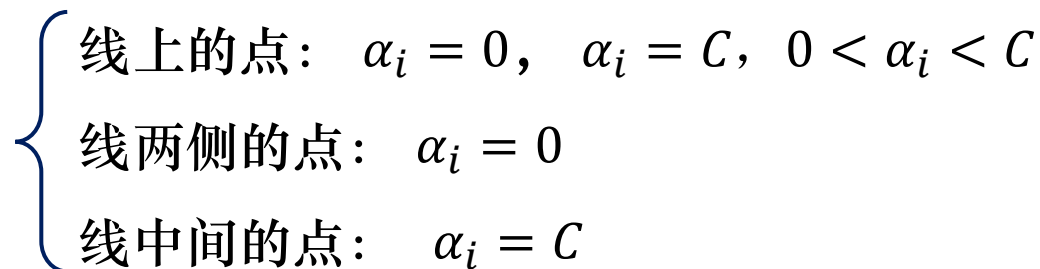
1. 线性情况

- 不完全可分 (软间隔SVC)

对偶问题的解与样本位置的关系:



反之,




二、支持向量分类机 (SVC)



1. 线性情况

- 不完全可分 (软间隔SVC)

几何解释:



支持向量: 只要是 $\alpha_i \neq 0$ 对应的样本点都称为支持向量


(注: 支持向量有可能在线上, 可能不在线上, 并且线上的点不一定是支持向量)

二、支持向量分类机 (SVC)



2. 非线性情况

非线性可分：如果在低维空间中无法线性可分的样本，在高维空间中可以找到一个超平面可以将其分开



原因：非线性问题往往不好求解，所以希望能用解线性分类问题的方法解决

二、支持向量分类机 (SVC)



2. 非线性情况

主要思想：在原始空间中无法线性可分时，

- 将其映射到高维空间，使其在高维空间中线性可分
- 通过求解变换后的**线性问题**来求解原来的非线性问题

核函数：设 X 是输入空间， H 为特征空间，如果存在一个从 X 到 H 的映射：

$$\Phi: X \rightarrow H$$

使得对所有 $x, z \in X$ ，函数 $K(x, z)$ 满足条件：

$$K(x, z) = \varphi(x) \cdot \varphi(z)$$

则称 $K(x, z)$ 为核函数， $\varphi(x)$ 为映射函数。

二、支持向量分类机 (SVC)



2. 非线性情况

常见的核函数:

基本经验: 文本数据常用线性核,
情况不明时可先尝试高斯核

- 线性核: $K(x_i, x_j) = x_i^T x_j$
- 多项式核: $K(x_i, x_j) = (x_i^T x_j)^d$ ($d \geq 1$ 为多项式的次数)
- 高斯核:

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right) \quad (\sigma > 0 \text{ 为高斯核的带宽})$$

- 拉普拉斯核:

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|}{\sigma}\right) \quad (\sigma > 0)$$

- Sigmoid核:

$$K(x_i, x_j) = \tanh(\beta x_i^T x_j + \theta)$$

(\tanh 为双曲正切函数, $\beta > 0, \theta < 0$)


二、支持向量分类机 (SVC)




2. 非线性情况

核函数参数的取值不同分类效果也不同


举例：高斯核函数



$$\exp(-1||x_i - x_j||^2)$$



$$\exp(-10||x_i - x_j||^2)$$



$$\exp(-100||x_i - x_j||^2)$$

过拟合

一般通过交叉验证选取合适的核参数

二、支持向量分类机 (SVC)



2. 非线性情况

核函数在支持向量机中的应用

设样本 x 映射后的向量为 $\varphi(x)$ ，划分超平面为 $f(x) = w^T \varphi(x) + b$

原始问题:

$$\begin{aligned} \min_{w, b, \xi} \quad & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l \xi_i \\ \text{s. t.} \quad & y_i (w^T \varphi(x_i) + b) \geq 1 - \xi_i, \quad i = 1, \dots, l \\ & \xi_i \geq 0, \quad i = 1, \dots, l \end{aligned}$$

对偶问题:

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j K(x_i, x_j) \alpha_i \alpha_j - \sum_{j=1}^l \alpha_j \\ \text{s. t.} \quad & \sum_{i=1}^l y_i \alpha_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, \dots, l. \end{aligned}$$

预测:

$$f(x) = w^T \varphi(x) + b = \sum_{i=1}^l \alpha_i y_i K(x_i, x_j) + b$$

二、支持向量分类机 (SVC)




3. 拓展模型

① 最小二乘支持向量机 (LS-SVM)

主要思想： 将SVM优化问题的非等式约束用等式约束替换

几何解释：



- ① 间隔最小化
- ② 正负类样本点分别尽可能在两条虚线周围

二、支持向量分类机 (SVC)



3. 拓展模型

① 最小二乘支持向量机 (LS-SVM)

原问题:

$$\min_{w, \eta, b} \quad \frac{1}{2} \|w\|^2 + \frac{C}{2} \sum_{i=1}^l \eta_i^2$$
$$s. t. \quad y_i \left((w \cdot \phi(x_i)) + b \right) = 1 - \eta_i, i = 1, \dots, l$$

对偶模型:

$$\min_{\alpha} \quad -\frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j \left(K(x_i, x_j) + \frac{\delta_{ij}}{C} \right) \alpha_i \alpha_j + \sum_{i=1}^l \alpha_i$$
$$s. t. \quad \sum_{i=1}^l y_i \alpha_i = 0$$

其中 $\delta_{ij} = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$

二、支持向量分类机 (SVC)




3. 拓展模型

② ν -支持向量机 (ν -SVM)

主要思想：用参数 ν 代替原始SVM中的参数 C ，使参数具有一定的含义

几何解释：



注：当 $\rho = 1$ 时，即为原始的SVM

二、支持向量分类机 (SVC)



3. 拓展模型

② ν -支持向量机 (ν -SVM)

原问题:

$$\begin{aligned} \min_{w, b, \xi, \rho} \quad & \frac{1}{2} \|w\|^2 - \nu \rho + \frac{1}{l} \sum_{i=1}^l \xi_i \\ \text{s. t.} \quad & y_i(w \cdot \phi(x_i) + b) \geq \rho - \xi_i, \quad i = 1, \dots, l \\ & \xi_i \geq 0, i = 1, \dots, l; \quad \rho \geq 0 \end{aligned}$$

对偶问题:

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j K(x_i, x_j) \alpha_i \alpha_j \\ \text{s. t.} \quad & \sum_{i=1}^l y_i \alpha_i = 0 \\ & \sum_{i=1}^l \alpha_i \geq \nu \\ & 0 \leq \alpha_i \leq \frac{1}{l}, \quad i = 1, \dots, l. \end{aligned}$$

二、支持向量分类机 (SVC)



3. 拓展模型

② ν -支持向量机 (ν -SVM)

参数 ν 的意义:

间隔错误训练点: 没有被“充分”正确划分的训练点

- 若记间隔错误训练点的个数为 p , 则 $\nu \geq \frac{p}{l}$
(ν 是建个错误训练点的个数所占总训练点数的上界)
- 若记支持向量的个数为 q , 则 $\nu \leq \frac{q}{l}$
(ν 是支持向量的个数所占总训练点数的下界)

二、支持向量分类机 (SVC)




3. 拓展模型

③ U -支持向量机 (U -SVM)

给定训练集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_l, y_l)\}$, 其中 $x_i \in R^n$, $y_i \in \{-1, +1\}$, 和无类别标记的样本集合 $U = \{x_1^*, \dots, x_u^*\}$.

几何解释:



- ① 正负类样本点尽可能在两条黑色虚线以外
- ② U -类点尽可能在两条绿色虚线中间

二、支持向量分类机 (SVC)



3. 拓展模型

③ U -支持向量机 (U -SVM)

原问题:

$$\min_{w, b, \xi, \psi} \frac{1}{2} \|w\|^2 + C_t \sum_{i=1}^l \xi_i + C_u \sum_{s=1}^u (\psi_s + \psi_s^*)$$
$$s. t. \quad y_i(w \cdot x_i + b) \geq 1 - \xi_i, \xi_i \geq 0, i = 1, \dots, l$$
$$-\varepsilon - \psi_s^* \leq (w \cdot x_s^*) + b \leq \varepsilon + \psi_s, s = 1, \dots, u$$
$$\psi_s, \psi_s^* \geq 0, s = 1, \dots, u$$

对偶问题:

$$\max_{\alpha, \mu, \nu} -\frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \frac{1}{2} \sum_{s,t=1}^u (\mu_s - \nu_s)(\mu_t - \nu_t) K(x_s^*, x_t^*)$$
$$- \sum_{i=1}^l \sum_{s=1}^u \alpha_i y_i (\mu_s - \nu_s) K(x_i, x_s^*) + \sum_{i=1}^l \alpha_i - \varepsilon \sum_{s=1}^u (\mu_s + \nu_s)$$
$$s. t. \quad \sum_{i=1}^l y_i \alpha_i + \sum_{s=1}^u (\mu_s - \nu_s) = 0$$
$$C_t - \alpha_i - \eta_i = 0, i = 1, \dots, l$$
$$C_u - \nu_s - \gamma_s = 0, s = 1, \dots, u$$
$$C_u - \mu_s - \gamma_s^* = 0, s = 1, \dots, u$$
$$\nu_s, \gamma_s \geq 0, s = 1, \dots, u$$
$$\mu_s, \gamma_s^* \geq 0, s = 1, \dots, u$$

注：充分利用了未标记的样本，
但对偶问题的规模变大

二、支持向量分类机 (SVC)




3. 拓展模型

④ 双子支持向量机 (TSVM)

主要思想：通过构造两条非平行的超平面，分离正负类样本点

几何解释：



- ① 正类样本点尽可能在红色实线周围
- ② 负类样本点尽可能在红色虚线下方

二、支持向量分类机 (SVC)



3. 拓展模型

④ 双子支持向量机 (TSVM)

原问题:

$$\min_{w^{(1)}, b^{(1)}, q} \frac{1}{2} (Aw^{(1)} + e_1 b^{(1)})^T (Aw^{(1)} + e_1 b^{(1)}) + c_1 e_2^T q$$
$$s. t. -(Bw^{(1)} + e_2 b^{(1)}) + q \geq e_2, q \geq 0$$

$$\min_{w^{(2)}, b^{(2)}, q} \frac{1}{2} (Bw^{(2)} + e_2 b^{(2)})^T (Bw^{(2)} + e_2 b^{(2)}) + c_2 e_1^T q$$
$$s. t. (Aw^{(2)} + e_1 b^{(2)}) + q \geq e_1, q \geq 0$$

对偶问题:

$$\max_{\alpha} e_2^T \alpha - \frac{1}{2} \alpha^T G (H^T H)^{-1} G^T \alpha$$
$$s. t. 0 \leq \alpha \leq c_1$$
$$\max_{\gamma} e_1^T \gamma - \frac{1}{2} \gamma^T P (Q^T Q)^{-1} P^T \gamma$$
$$s. t. 0 \leq \gamma \leq c_2$$

二、支持向量分类机 (SVC)




3. 拓展模型

⑤ 多分类支持向量机 (1 vs 1)

主要思想：将多分类问题转化为多个二分类问题处理

几何解释：



二、支持向量分类机 (SVC)



4. 求解算法:

序列最小化算法: (SMO)

基本思想:

- 如果 α^* 的所有分量都满足KKT条件, 那么 α^* 即为最优解
- 否则, 选择 α^* 两个分量, 固定其他分量,
- 针对这两个变量构建一个二次规划问题, 然后求解它,
- 直到所有分量都满足KKT条件

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l y_i y_j (x_i, x_j) \alpha_i \alpha_j - \sum_{j=1}^l \alpha_j \\ \text{s. t.} \quad & \sum_{i=1}^l y_i \alpha_i = 0 \\ & 0 \leq \alpha_i \leq C, \quad i = 1, \dots, l. \end{aligned}$$

二、支持向量分类机 (SVC)



4. 求解算法:

常用算法总结

Algorithm	Citation	SVM type	Optimization type	Style	Runtime
SMO	[Platt, 1999]	Kernel	Dual QP	Batch	$\Omega(n^2 d)$
SVM ^{light}	[Joachims, 1999]	Kernel	Dual QP	Batch	$\Omega(n^2 d)$
Core Vector Machine	[Tsang et al., 2005, 2007]	SL Kernel	Dual geometry	Batch	$O(s/\rho^4)$
SVM ^{perf}	[Joachims, 2006]	Linear	Dual QP	Batch	$O(ns/\lambda\rho^2)$
NORMA	[Kivinen et al., 2004]	Kernel	Primal SGD	Online(-style)	$\tilde{O}(s/\rho^2)$
SVM-SGD	[Bottou, 2007]	Linear	Primal SGD	Online-style	Unknown
Pegasos	[Shalev-Shwartz et al., 2007]	Kernel	Primal SGD/SGP	Online-style	$\tilde{O}(s/\lambda\rho)$
LibLinear	[Hsieh et al., 2008]	Linear	Dual coordinate descent	Batch	$O(nd \cdot \log(1/\rho))$
SGD-QN	[Bordes and Bottou, 2008]	Linear	Primal 2SGD	Online-style	Unknown
FOLOS	[Duchi and Singer, 2008]	Linear	Primal SGP	Online-style	$\tilde{O}(s/\lambda\rho)$
BMRM	[Smola et al., 2007]	Linear	Dual QP	Batch	$O(d/\lambda\rho)$
OCAS	[Franc and Sonnenburg, 2008]	Linear	Primal QP	Batch	$O(nd)$



➤ 支持向量回归机

三、支持向量回归机 (SVR)




1. 线性情况

给定训练集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_l, y_l)\}$, 其中 $x_i \in R^n$, $y_i \in R$

主要思想： 构建尽可能窄的 ϵ 带子, 使的最终拟合线落在中间

几何解释：



- 间隔越小越好
- 斜率越小越好
- 使的所有样本点尽可能在两条虚线中间

三、支持向量回归机 (SVR)



1. 线性情况

原问题:

$$\min_{w, b, \xi_i, \xi_i^*} \frac{1}{2} \|w\|^2 + c \sum_{i=1}^n (\xi_i + \xi_i^*)$$
$$s. t. \quad y_i - (x_i^T w + b) \leq \epsilon + \xi_i,$$
$$(x_i^T w + b) - y_i \leq \epsilon + \xi_i^*,$$
$$\xi_i \geq 0, \xi_i^* \geq 0, i = 1, 2, \dots, n.$$

对偶模型:

$$\min_{\alpha} \frac{1}{2} \sum_{i, j=1}^l (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j)(x_i \cdot x_j) + \epsilon \sum_{i=1}^l (\alpha_i^* + \alpha_i) - \sum_{i=1}^l y_i (\alpha_i^* - \alpha_i)$$
$$s. t. \quad \sum_{i=1}^l (\alpha_i - \alpha_i^*) = 0 \quad 0 \leq \alpha_i^{(*)} \leq C, i = 1, \dots, l.$$

预测:

$$y = g(x) = \sum_{i=1}^l (\bar{\alpha}_i^* - \bar{\alpha}_i)(x_i \cdot x) + \bar{b}$$

三、支持向量回归机 (SVR)



1. 线性情况

引入拉格朗日函数:

$$L(w, b, \xi^{(*)}, \alpha^{(*)}, \eta^{(*)}) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l (\xi_i + \xi_i^*) - \sum_{i=1}^l (\beta_i \xi_i + \beta_i^* \xi_i^*) \\ - \sum_{i=1}^l \alpha_i (\varepsilon + \xi_i + y_i - (w \cdot x_i) - b) - \sum_{i=1}^l \alpha_i^* (\varepsilon + \xi_i^* - y_i + (w \cdot x_i) + b)$$

最优性条件:

① $\frac{\partial L}{\partial w} = w + \sum_{i=1}^l \alpha_i x_i - \sum_{i=1}^l \alpha_i^* x_i = 0$	⑤ $\alpha_i (\varepsilon + \xi_i + y_i - (w \cdot x_i) - b) = 0$
② $\frac{\partial L}{\partial b} = \sum_{i=1}^l \alpha_i - \sum_{i=1}^l \alpha_i^* = 0$	⑥ $\alpha_i^* (\varepsilon + \xi_i^* - y_i + (w \cdot x_i) + b) = 0$
③ $\frac{\partial L}{\partial \xi_i} = C - \alpha_i - \beta_i = 0$	⑦ $\beta_i \xi_i = 0$
④ $\frac{\partial L}{\partial \xi_i^*} = C - \alpha_i^* - \beta_i^* = 0$	⑧ $\beta_i^* \xi_i^* = 0$
	⑨ $(w \cdot x_i) + b - y_i \leq \varepsilon + \xi_i$
	⑩ $y_i - (w \cdot x_i) - b \leq \varepsilon + \xi_i^*$

三、支持向量回归机 (SVR)



1. 线性情况

对偶问题的解与样本位置的关系：

$$\alpha_i = 0 \xrightarrow{\textcircled{3}} \beta_i = C \xrightarrow{\textcircled{7}} \xi_i = 0 \xrightarrow{\textcircled{9}} (w \cdot x_i) + b - y_i \leq \varepsilon$$

$$\alpha_i^* = 0 \xrightarrow{\textcircled{4}} \beta_i^* = C \xrightarrow{\textcircled{8}} \xi_i^* = 0 \xrightarrow{\textcircled{10}} y_i - (w \cdot x_i) - b \leq \varepsilon$$

$$\alpha_i = C \xrightarrow{\textcircled{3}} \beta_i = 0 \xrightarrow{\textcircled{7}} \xi_i \geq 0 \xrightarrow{\textcircled{5}} (w \cdot x_i) + b - y_i \geq \varepsilon$$

$$\alpha_i^* = C \xrightarrow{\textcircled{4}} \beta_i^* = 0 \xrightarrow{\textcircled{8}} \xi_i^* \geq 0 \xrightarrow{\textcircled{6}} y_i - (w \cdot x_i) - b \geq \varepsilon$$

$$0 < \alpha_i < C \xrightarrow{\textcircled{3}} \beta_i \neq 0 \xrightarrow{\textcircled{7}} \xi_i = 0 \xrightarrow{\textcircled{5}} (w \cdot x_i) + b - y_i = \varepsilon$$


$$0 < \alpha_i^* < C \xrightarrow{\textcircled{4}} \beta_i^* \neq 0 \xrightarrow{\textcircled{8}} \xi_i^* = 0 \xrightarrow{\textcircled{6}} y_i - (w \cdot x_i) - b = \varepsilon$$

三、支持向量回归机 (SVR)



1. 线性情况

几何解释:




Yellow region (above $f(x) + \epsilon$)	$\alpha_i = 0, \alpha_i^* = C$
Green region (between $f(x) + \epsilon$ and $f(x) - \epsilon$)	$\alpha_i = 0, 0 \leq \alpha_i^* \leq C$
Light green region (between $f(x)$ and $f(x) + \epsilon$)	$\alpha_i = 0, \alpha_i^* = 0$
Light blue region (between $f(x)$ and $f(x) - \epsilon$)	$0 \leq \alpha_i \leq C, \alpha_i^* = 0$
Orange region (below $f(x) - \epsilon$)	$\alpha_i = C, \alpha_i^* = 0$

三、支持向量回归机 (SVR)



2. 非线性情况

线性不可分:



三、支持向量回归机 (SVR)



2. 非线性情况

原问题:

$$\begin{aligned} \min_{w, b, \xi_i, \xi_i^*} \quad & \frac{1}{2} \|w\|^2 + c \sum_{i=1}^n (\xi_i + \xi_i^*) \\ \text{s.t.} \quad & y_i - (\varphi(x_i)^T w + b) \leq \epsilon + \xi_i, \\ & (\varphi(x_i)^T w + b) - y_i \leq \epsilon + \xi_i^*, \\ & \xi_i \geq 0, \xi_i^* \geq 0, i = 1, 2, \dots, n. \end{aligned}$$

对偶模型:

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i,j=1}^l (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) K(x_i \cdot x_j) + \epsilon \sum_{i=1}^l (\alpha_i^* + \alpha_i) - \sum_{i=1}^l y_i (\alpha_i^* - \alpha_i) \\ \text{s.t.} \quad & \sum_{i=1}^l (\alpha_i - \alpha_i^*) = 0 \quad 0 \leq \alpha_i^{(*)} \leq C, i = 1, \dots, l. \end{aligned}$$

预测:

$$y = g(x) = \sum_{i=1}^l (\bar{\alpha}_i^* - \bar{\alpha}_i) K(x_i \cdot x) + \bar{b}$$

三、支持向量回归机 (SVR)



3. 拓展模型

① 最小二乘支持向量回归机 (LS-SVR)

将SVR模型中的不等式约束改为等式约束

① ν -支持向量回归机 (ν -SVR)

用参数 ν 代替原始SVM中的参数 C ，使参数具有一定的含义

① 双子支持向量回归机 (TSVR)

通过构造两条非平行的 ϵ 超平面，得到最终的拟合超平面



➤ 非平衡支持向量机

四、非平衡类支持向量机




非平衡类支持向量机是处理非平衡数据的一种有效的手段

1. One-class SVM

主要思想： 只有一类训练点时，我们只利用这一类点，构造最优超平面

几何解释：



- ① 所有样本点尽可能远离坐标原点
- ② 超平面尽可能远离坐标原点

四、非平衡类支持向量机



1. One-class SVM

原问题:

$$\begin{aligned} \min_{w, \xi, \rho} & \frac{1}{2} \|w\|^2 - \rho + \frac{1}{\nu l} \sum_{i=1}^l \xi_i \\ \text{s. t. } & y_i (w \cdot \phi(x_i)) \geq \rho - \xi_i, \quad i = 1, \dots, l \\ & \xi_i \geq 0, i = 1, \dots, l; \end{aligned}$$

对偶问题:

$$\begin{aligned} \min_{\alpha} & \frac{1}{2} \sum_{i=1}^l \sum_{j=1}^l (x_i, x_j) \alpha_i \alpha_j \\ \text{s. t. } & \sum_{i=1}^l \alpha_i = 1 \\ & 0 \leq \alpha_i \leq \frac{1}{\nu l}, \quad i = 1, \dots, l. \end{aligned}$$

四、非平衡类支持向量机




2. 球类支持向量机

① SVDD

主要思想： 只利用数量较多的那一类，构造最优超平面

几何解释：



- ① 正类样本点尽可能在圆内
- ② 负类样本点尽可能在圆外

四、非平衡类支持向量机



① SVDD

原问题:

$$\begin{aligned} \min_{R^2, C, \xi} \quad & R^2 + \frac{1}{v_1 l^+} \sum_{i=1}^{l^+} \xi_i + \frac{1}{v_2 l^-} \sum_{j=1}^{l^-} \xi_j \\ \text{s. t.} \quad & \|\phi(x_i) - C\|^2 \leq R^2 + \xi_i \\ & \|\phi(x_j) - C\|^2 \geq R^2 - \xi_j \\ & \xi_k \geq 0 \end{aligned}$$

对偶问题:

$$\begin{aligned} \min_{\alpha} \quad & \alpha^T \begin{bmatrix} K(A, A) & -K(A, B) \\ -K(B, A) & K(B, B) \end{bmatrix} \alpha - \alpha^T \begin{bmatrix} K_{AA} \\ -K_{BB} \end{bmatrix} \\ \text{s. t.} \quad & \sum_{i=1}^{l^+} \alpha_i - \sum_{j=1}^{l^-} \beta_j = 1 \\ & 0 \leq \alpha_i \leq \frac{1}{v_1 l^+}, 0 \leq \beta_j \leq \frac{1}{v_2 l^-} \end{aligned}$$

决策函数:

$$f(x) = \begin{cases} 1, & \text{if } \|\phi(x) - C\|^2 \leq R^2 \\ -1, & \text{otherwise} \end{cases}$$

四、非平衡类支持向量机



① SVDD

球心 C 和半径 R 的求解:

构造拉格朗日函数:

$$L = R^2 + \frac{1}{v_1 l^+} \sum_{i=1}^{l^+} \xi_i + \frac{1}{v_2 l^-} \sum_{j=1}^{l^-} \xi_j + \sum_{i=1}^{l^+} \alpha_i (\|\phi(x_i) - C\|^2 - R^2 - \xi_i) \\ - \sum_{j=1}^{l^-} \beta_j (\|\phi(x_j) - C\|^2 - R^2 + \xi_j) - \sum_{k=1}^n \lambda_k \xi_k$$

关于参数 R^2, C, ξ_i 求导数:

$$\frac{\partial L}{\partial R^2} = 1 - \sum_{i=1}^{l^+} \alpha_i + \sum_{j=1}^{l^-} \beta_j \Rightarrow \sum_{i=1}^{l^+} \alpha_i + \sum_{j=1}^{l^-} \beta_j = 1$$

$$\frac{\partial L}{\partial C} = -2 \sum_{i=1}^{l^+} \alpha_i (\phi(x_i) - C) + 2 \sum_{j=1}^{l^-} \beta_j (\phi(x_j) - C) = 0$$

四、非平衡类支持向量机



① SVDD

球心 C 和半径 R 的求解:

$$\frac{\partial L}{\partial \xi_i} = \frac{1}{v_1 l^+} - \alpha_i - \lambda_i = 0 \quad \alpha_i (\|\phi(x_i) - C\|^2 - R^2 - \xi_i) = 0$$

$$\frac{\partial L}{\partial \xi_j} = \frac{1}{v_2 l^-} - \beta_j - \lambda_j = 0 \quad \beta_j (\|\phi(x_j) - C\|^2 - R^2 + \xi_j) = 0$$

可知: 当 $0 < \alpha_i < \frac{1}{v_1 l^+}$, 有 $R^2 = \|\phi(x_i - C)\|^2$

当 $0 < \beta_j < \frac{1}{v_2 l^-}$, 有 $R^2 = \|\phi(x_j - C)\|^2$


四、非平衡类支持向量机



② 最小球最大间隔法 (SSLM)

主要思想：同时利用正负类样本点，构造两个同心球超平面

几何解释：



- ① 正类样本点尽可能在红色圆内
- ② 负类样本点尽可能在蓝色圆外
- ③ 两球间隔尽量大

四、非平衡类支持向量机



② 最小球最大间隔法 (SSLM)

原问题:

$$\min_{R^2, C, \rho^2, \xi} R^2 - \nu \rho^2 + \frac{1}{v_1 l^+} \sum_{i=1}^{l^+} \xi_i + \frac{1}{v_2 l^-} \sum_{j=1}^{l^-} \xi_j$$
$$s. t. \quad \|\phi(x_i) - C\|^2 \leq R^2 + \xi_i, i \in I^+$$
$$\|\phi(x_j) - C\|^2 \geq R^2 + \rho^2 - \xi_j, j \in I^-$$
$$\xi_k \geq 0, k = 1, 2, \dots, l$$

对偶问题:

$$\min_{\alpha} \alpha^T \begin{bmatrix} K(A, A) & -K(A, B) \\ -K(B, A) & K(B, B) \end{bmatrix} \alpha - \alpha^T \begin{bmatrix} K_{AA} \\ -K_{BB} \end{bmatrix}$$
$$s. t. \quad \begin{cases} \alpha^T y = 1 \\ \alpha^T e = 2\nu + 1 \end{cases} \Leftrightarrow \alpha^T [y \quad e] = [1 \quad 2\nu + 1]$$
$$0 \leq \alpha \leq \begin{bmatrix} \frac{1}{v_1 l^+} \\ \frac{1}{v_2 l^1} \end{bmatrix}$$

决策函数:

$$f(x_t) = \begin{cases} 1, & \text{if } \|\phi(x_i) - C\| < \frac{R + \sqrt{R^2 + \rho^2}}{2} \\ -1, & \text{else} \end{cases}$$


四、非平衡类支持向量机



③ 双子球支持向量机

主要思想：同时利用正负类样本点，构造两个球超平面

几何解释：



- ① 正类样本点尽可能在红色圆内
- ② 负类样本点尽可能在蓝色圆内

四、非平衡类支持向量机



③ 双子球支持向量机

原问题:
$$\min_{C_+, R_+^2, \xi_i} R_+^2 - \frac{\nu_1}{l^+} \sum_{j \in I^-} \|\phi(x_j) - C_+\|^2 + \frac{c_1}{l^+} \sum_{i \in I^+} \xi_i$$

$$s. t. \quad \|\phi(x_i) - C_+\|^2 \leq R_+^2 + \xi_i$$

$$R_+^2 \geq 0, \xi_i \geq 0, i \in I^+$$

$$\min_{C_-, R_-^2, \xi_j} R_-^2 - \frac{\nu_2}{l^-} \sum_{i \in I^+} \|\phi(x_i) - C_-\|^2 + \frac{c_2}{l^-} \sum_{j \in I^-} \xi_j$$

$$s. t. \quad \|\phi(x_j) - C_-\|^2 \leq R_-^2 + \xi_j$$

$$R_-^2 \geq 0, \xi_j \geq 0, j \in I^-$$

决策函数:
$$f(x) = \arg \min_{+,-} \left\{ \frac{\|\phi(x) - C_+\|^2}{R_+^2}, \frac{\|\phi(x) - C_-\|^2}{R_-^2} \right\}$$

(距离哪个球近就属于哪一类)



➤ 总结

1. 支持向量分类机

线性SVM、非线性SVM，拓展模型，求解算法

2. 支持向量回归机

线性SVR、非线性SVR，拓展模型

3. 球类支持向量机

OCSVM, SVDD、SSLM、THSVM

优点:

- ① **小样本**: 并不是说样本的绝对数量少, 而是说与问题的复杂度比起来, SVM算法要求的样本数是相对比较小的
- ② **非线性**: SVM擅长应付样本数据线性不可分的情况, 主要通过松弛变量 (也有人叫惩罚变量) 和核函数技术来实现
- ③ **高维模式识别**: 指样本维数很高, SVM可以处理高维向量, 因为SVM产生的分类器很简洁, 用到的样本信息很少 (仅仅用到那些称之为“支持向量”的样本)

缺点:

- ① 如果特征维度远远大于样本数, 则SVM表现一般
- ② SVM在样本量非常大, 计算量过大
- ③ 难以选择一个合适的核函数
- ④ SVM对缺失数据敏感



中國農業大學
China Agricultural University

谢 谢 !

